

CAN: Redes Adversarial Creativas

Lesly Yaneth Mita Yagua¹¹Universidad Nacional de San Agustín, Facultad de Producción y Servicios, Escuela de Ciencia de la ComputaciónEdited by
(Editor)Reviewed by
(Reviewer 1)
(Reviewer 2)Received
01 November 2018

Published

DOI

0.1 Resumen

Dentro del arte visual, se han propuesto varios sistemas para crear arte automáticamente, no solo en el dominio de la inteligencia artificial y la creatividad computacional, sino también en gráficos por computadora y aprendizaje automático. Dentro de la literatura sobre creatividad computacional, se han propuesto diferentes algoritmos enfocados a investigar diversas y efectivas formas de explorar el espacio creativo. El objetivo del artículo CAN: *Creative Adversarial Networks Generating "Art" by Learning About Styles and Deviating from Style Norms* [1] es proponer un nuevo sistema de generación de arte, que genera arte mirando el arte y aprendiendo sobre estilo; y se vuelve creativo aumentando el potencial de excitación del arte generado desviándose de los estilos aprendidos. Las Redes Adversarias Generativas (GAN), que han demostrado la capacidad de aprender a generar imágenes novedosas simulando una distribución determinada. Por ello realizaron modificaciones a su objetivo para que sea capaz de generar arte creativo maximizando la desviación de los estilos establecidos y minimizando la desviación de la distribución del arte. Los experimentos realizados para comparar la respuesta de sujetos humanos al arte generado con su respuesta al arte creado por artistas. Los resultados muestran que los sujetos humanos no pudieron distinguir el arte generado por el sistema propuesto del arte generado por artistas contemporáneos y exhibido en las principales ferias de arte.

0.2 Introducción

A lo largo del tiempo, la capacidad de la máquina se ha explorado para generar productos creativos a nivel humano, tanto la creatividad como la innovación son procesos en los que se produce una búsqueda y combinación de datos con el objetivo de llegar a algo nuevo. Las máquinas son excelentes almacenando, procesando datos y creando conexiones entre ellas, por ello se han propuesto muchos sistemas para producir arte en distintas áreas de la computación. Algunos sistemas utilizaban dentro del proceso a un ser humano para guiarlo, donde desempeña un papel de observador presentando una retroalimentación para impulsar el proceso creativo mientras la máquina explora el espacio creativo [2].

Dentro del marco de algoritmo genético se encuentra un proceso evolutivo en el que el algoritmo itera generando candidatos, evaluándolos mediante una función de aptitud y luego modificándolos para mejorar la puntuación de aptitud para la siguiente iteración [3]. Además un componente esencial en los algoritmos de generación de arte es relacionar su proceso creativo con el arte que ha sido producido por artistas humanos a lo largo del tiempo. Es importante porque el proceso creativo de un ser humano utiliza la experiencia previa y la exposición al arte.

Una teoría para modelar cómo integrar la exposición al arte con la creación de arte es la de Colin Martindale (1943-2008) basada en la psicología explica la creación de un nuevo

Copyright © 2019, released under a Creative Commons Attribution 4.0 International license.

Correspondence should be addressed to Lesly Yaneth Mita Yagua (lmita@unsa.edu.pe)

The authors have declared that no competing interests exists.

Code is available at <https://github.com/rescience-c/template>.

arte mediante la hipótesis de que los artistas creativos intentan aumentar el potencial de excitación de su arte para luchar contra la habituación, sin embargo este aumento debe ser mínimo para evitar reacciones negativas por parte de los observadores. También planteó la hipótesis de que los cambios de estilo ocurren como una forma de aumentar el potencial de excitación del arte cuando los artistas ejercen otros medios dentro de los roles del estilo [4].

La Inteligencia Artificial ha desempeñado recientemente un papel transformador en varios dominios de aplicaciones, en particular las Redes Generativas Profundas (GAN) por sus siglas en inglés Generative Adversarial Networks, basados en redes neuronales profundas han demostrado tener la capacidad de generar imágenes novedosas para emular una distribución de entrenamiento dada [5]. GAN posee dos subredes, un generador y un discriminador. El discriminador tiene acceso a un conjunto de imágenes, este intenta distinguir entre imágenes reales e imágenes falsas producidas por el generador. El generador intenta producir imágenes similares al conjunto de entrenamiento sin ver estas imágenes. El generador comienza produciendo imágenes aleatorias y recibe una señal del discriminador si el discriminador las encuentra reales o falsas [6].

0.3 Trabajos relacionados

La investigación y teoría sobre el desarrollo artístico como un esfuerzo cultural y creativo puede ser examinada desde los orígenes del arte humano, como parte de una transformación cultural en el crecimiento de un artista creativo. [7] Distintos investigadores han propuesto teorías artísticas identificando patrones ocultos y relaciones presentes, analizando su complejidad. [8] Obteniendo al ser humano como un artista nato, cuestionándonos si una computadora lograría generar arte siendo este tan propio del ser humano.

La tecnología informática ofrece nuevas condiciones y posibilidades para arte creación e investigación, y también amplía las formas de artística expresión. Creado por computadora arte se ha convertido así en una de las formas importantes de arte. En la actualidad existen antecedentes de la capacidad computacional del procesamiento de imágenes como sintetizar automáticamente collages visualmente agradables por medio de percepción visual [9], además de la gran capacidad de clasificación que ha demostrado a lo largo de los años debido a que algunos procesos resultan complicados y requieren mucho tiempo para su elaboración, no obstante los modelos computacionales derivando principios y heurísticas logran dar una solución a esta problemática. [10] En la actualidad, existen diversas técnicas computacionales para la clasificación de imágenes dentro de ellas Convolutional Neural Network (CNN) [11] y las variaciones con algoritmos genéticos como Particle Swarm Optimization (PSO) para abordar estrategias de búsqueda durante el proceso. [12] La clasificación de imágenes artísticas implica la identificación automática de clases visuales presentes en una obra de arte, tales como calcular las similitudes en términos de apariencia, anotación manual, [13] identificar correctamente el estilo artístico, autenticación de pintores, [14] etc. Siendo el objetivo del análisis automático de pinturas a gran escala es clasificar y recuperar imágenes utilizando técnicas de aprendizaje automático. [15] [16] Si bien la clasificación de imágenes es computacionalmente factible, los antecedentes sobre la generación de imágenes demuestran que son posibles, como representar la expresión de la emoción visual en la cara hablante sincronizada con el discurso y expresando la emoción condicionada; [17] como generar arte crea animaciones 3D mediante la ejecución de PSO sobre paisajes sintéticos producidos; [18] como generar un subtítulo de historia corta (SSCap) usando un conjunto de datos de subtítulos y un corpus de historias recopilado manualmente, [19]; como a partir de una unidad textual como palabra, frase, cláusula y oración generar nuevas imágenes; [20] desde luego se ha generado imágenes por medio de robots para crear dibujos a lápiz realistas utilizando algoritmos genéticos [21] también se ha logrado generar cómics a partir de videos sin ninguna intervención humana, extrayendo fotogramas claves informativos mediante el análisis de los subtítulos. [22]

Generar imágenes específicamente artísticas, ha sido estudiada desde distintas técnicas computacionales, como la computación paralela donde investigadores proponen un mosaico imagen generacional basado en el enfoque codicioso que se basa en la característica del sistema visual humano para optimizar las imágenes generadas. [23] Sin embargo, uno de los primeros artículos sobre generación de imágenes artísticas utilizaba una técnica de mapeo de desviación construido a partir de un solo fondo imagen donde el mapa de desviación puede considerarse como una superficie virtual luego se pinta con un primer plano imagen iluminado para generar el resultado final. [24] Además también se han propuesto algoritmos para la generación de imágenes artísticas como Algorithmic Painter que puede producir varios estilos de pintura a partir de fotografías originales, siendo un método de representación pictórica, por lo que es altamente expresivo, pero aún conserva las características esenciales de la foto original; [25] así como otros algoritmos que crearon su propia estructura para la generación de pinturas artísticas.[26] [27] No obstante, algunos investigadores implementaron esta generación de pinturas con la finalidad de ser utilizada en diversas plataformas que tienen el rendimiento informático diferente y la resolución de pantalla siendo capaz de producir una pintura con estilo artístico. [28]

Dentro del proceso de generación de arte, las características del diseño del patrón, como la repetición, los marcos, las curvas, la direccionalidad y los acentos visuales únicos existen los mecanismos de control de las técnicas para permitir la intención del artista. [29] Anteriormente se menciona que era posible la generación de imágenes artísticas, pero no necesariamente estas son creativas y novedosas, ya que conservan la similitud de la imagen original. Por ello es necesario comprender mejor el potencial de las técnicas actuales para el diseño creativo y la estimulación permiten la creatividad.

Las redes neuronales profundas son capaces de producir imágenes fotográficas que representan descripciones de texto en lenguaje natural dadas. La Red Adversaria Generativa (GAN) es la tendencia reciente de transformación de imagen a imagen. [30] Estos modelos tienen un enorme potencial en aplicaciones como diseño de interiores, videojuegos, edición y bocetos faciales para análisis forense digital. [31] Estas arquitecturas son capaces de transformar fotos faciales en retratos utilizando diferentes estilos de dibujo, [32] generar imágenes de personas condicionadas tanto por la pose como por la información de apariencia, [33] enerar imágenes con estilo de porcelana cantonesa utilizando máscaras definidas por el usuario [34]. La transferencia de estilo es de gran interés dados los avances recientes en las redes generativas de confrontación (GAN). Sin embargo, es un desafío generar imágenes sintetizadas a partir de máscaras abstractas mientras se preservan patrones detallados para ciertos tipos de arte dados pequeños conjuntos de datos para lograr que sea una generación creativa e innovadora.

0.4 Métodos y materiales

Los artistas humanos integran su conocimiento del arte pasado con su capacidad para generar nuevas formas siendo novedosos y creativos. Por ello se requiere una teoría para modelar cómo integrar la exposición al arte con la creación de arte que sea computacionalmente factible para lograr modificar los objetivos de GAN siendo capaz de generar arte creativo maximizando la desviación de los estilos establecidos y minimizando la desviación de la distribución del arte. Debido a que cuando GAN se encuentra en equilibrio, el discriminador no debería poder diferenciar entre las imágenes producidas por el generador y las imágenes reales, por lo que el generador logra producir imágenes que provienen de la misma distribución que el conjunto de entrenamiento. Sin embargo, si se entrena un modelo GAN sobre imágenes de pinturas, el generador solo generará imágenes que se parecen al arte ya existente, por lo tanto, el arte generado no sería novedoso ni creativo.

Sin embargo, si se modifica la función de pérdida de GAN y se agrega una pérdida de clasificación de estilo y una pérdida de ambigüedad de estilo. Se puede maximizar la ambigüedad estilística maximizando la entropía posterior de la clase de estilo.

El enfoque propuesto está inspirado en el principio de mínimo esfuerzo de Martindale y su explicación de los cambios de estilo. Entre las teorías que intentan explicar el progreso en el arte, encontramos que la teoría de Martindale es computacionalmente factible. Basado en la teoría de Martindale, al realizar modificaciones al objetivo de GAN para que sea capaz de generar arte creativo maximizando la desviación de los estilos establecidos y minimizando la desviación de la distribución del arte como se muestra en la Figura 1.

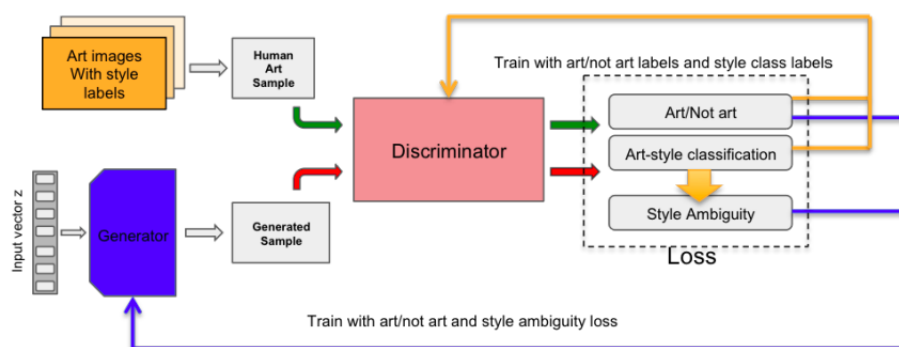


Figure 1. Diagrama de bloques del modelo [1].

Conjunto de datos – WikiArt es una enciclopedia de arte visual, el cual se utilizó para fines de extracción de datos utilizando el conjunto de datos en Kaggle a continuación se detallará descripciones de los archivos:

- *train.zip* que contiene las imágenes del conjunto de entrenamiento (.jpg)
- *train_1,2, .. 9.zip* subconjuntos de *train.zip* debido a que el tamaño de los datos es grande.
- *test.zip* archivo zip que contiene las imágenes del conjunto de prueba (.jpg)
- *train_info.csv* archivo que enumera el nombre del archivo de la imagen, el ID del artista, el género, el estilo, la fecha y el título de las imágenes del conjunto de capacitación.
- *submit_info.csv* cada fila enumera un índice y los nombres de archivo de las dos imágenes para las que el algoritmo necesita hacer una predicción sobre si fueron creadas por el mismo artista.
- *sampleSubmission.csv* un archivo de envío de muestra con una columna para el número de comparación y la probabilidad prevista
- *replacements_for_corrupted_files.zip* 10 archivos en el tren y conjuntos de prueba que eran imágenes corruptas, estas son las imágenes correctas.

Algunos artistas tienen trabajo tanto en el conjunto de entrenamiento como en el de prueba, mientras que otros tienen trabajo solo en el conjunto de entrenamiento o simplemente en el conjunto de prueba. Además, existen 14 grupos cada uno con aproximadamente 1400 - 2000 imágenes. A continuación se detallará los campos de información:

- *train_info.csv*
 - *filename* el nombre del archivo de la imagen (los archivos de entrenamiento están en *train.zip*)

- *artist* un hash del nombre del artista
- *title* el título de la pintura, si está disponible (cadena)
- *style* el estilo de la pintura
- *genre* el género de la pintura
- *date* la fecha en que se creó la pintura, si se conoce.
- *submission_info.csv*
 - *index* número de fila que identifica al par
 - *image1* nombre de archivo de imagen (de test.zip)
 - *image2* nombre de archivo de imagen (de test.zip)
- *sampleSubmission.csv*
 - *index* número de fila que identifica al par
 - *sameArtist* probabilidad prevista de que *image1* e *image2* sean del mismo artista
- *all_data_info.csv*
 - *artist* nombre del artista
 - *date* año en que se creó la pintura, si está disponible
 - *genre* información de género de wikiart
 - *pixelsx*, *pixelsy* dimensiones de la imagen
 - *size_bytes* tamaño de la imagen en bytes
 - *source* la imagen se obtuvo de wikiart o de wikipedia
 - *style* información de estilo de wikiart
 - *title* título de la pintura
 - *artist_group* el conjunto de prueba se divide en 14 grupos, de modo que cada imagen del grupo se compara con todas las demás imágenes de ese grupo. Para las imágenes del conjunto de prueba, *artist_group* indica a cuál de los 14 subgrupos pertenece.
 - *in_train* la imagen está en el conjunto de entrenamiento (False si está en el conjunto de prueba)
 - *new_filename* el nombre del archivo de la imagen

0.5 Propuesta de reproducibilidad

En la Figura 1 se puede observar un diagrama del modelo de generación de arte creativo CAN a reproducir, para ello se utilizara mismo conjunto de datos WikiArt disponible. Además de emplear las variantes que presentan para la validación cualitativa y los sujetos humanos que evaluarán el modelo serán los estudiantes de la carrera profesional Ciencia de la Computación de la Universidad Nacional de San Agustín para la validación cuantitativa.

0.6 Limitaciones de reproducibilidad

0.7 Resultados

0.8 Discusiones

0.9 Conclusiones

References

1. A. M. Elgammal, B. Liu, M. Elhoseiny, and M. Mazzone. "CAN: Creative Adversarial Networks, Generating "Art" by Learning About Styles and Deviating from Style Norms." In: **CoRR** abs/1706.07068 (2017). arXiv: 1706.07068.
2. D. Heath and D. Ventura. "Before A Computer Can Draw, It Must First Learn To See." In: **Proceedings of the Seventh International Conference on Computational Creativity**. ICC2016. Paris, France: Sony CSL Paris, June 2016, pp. 172–179.
3. P. Machado, J. Romero, and B. Manaris. "Experiments in Computational Aesthetics: An Iterative Approach to Stylistic Change in Evolutionary Art." In: Jan. 2007, pp. 381–415.
4. C. Martindale. **The clockwork muse: The predictability of artistic change**. The clockwork muse: The predictability of artistic change. New York, NY, US: Basic Books, 1990, pp. xiv, 411–xiv, 411.
5. I. Goodfellow, J. Pouget-Abadie, M. Mirza, B. Xu, D. Warde-Farley, S. Ozair, A. Courville, and Y. Bengio. "Generative Adversarial Nets." In: **Advances in Neural Information Processing Systems**. Ed. by Z. Ghahramani, M. Welling, C. Cortes, N. Lawrence, and K. Q. Weinberger. Vol. 27. Curran Associates, Inc., 2014.
6. A. Creswell, T. White, V. Dumoulin, K. Arulkumaran, B. Sengupta, and A. A. Bharath. "Generative Adversarial Networks: An Overview." In: **IEEE Signal Processing Magazine** 35.1 (2018), pp. 53–65.
7. C. Lightfoot and C. Milbrath. **Art and human development**. English. Art and Human Development. Pages: 286. 2009.
8. J. Silva, D. Pratas, R. Antunes, S. Matos, and A. Pinho. "Automatic analysis of artistic paintings using information-based measures." In: **Pattern Recognition** 114 (2021).
9. Z. Yang, Q. Dai, and J. Zhang. "Visual perception driven collage synthesis." English. In: **Computational Visual Media** 8.1 (2022), pp. 79–91.
10. M. Bratkova, P. Shirley, and W. Thompson. "Artistic rendering of mountainous terrain." In: **ACM Transactions on Graphics** 28.4 (2009).
11. B. Fielding and L. Zhang. "Evolving deep denseblock architecture ensembles for image classification." English. In: **Electronics (Switzerland)** 9.11 (2020), pp. 1–31.
12. T. Lawrence, L. Zhang, C. Lim, and E.-J. Phillips. "Particle Swarm Optimization for Automatically Evolving Convolutional Neural Networks for Image Classification." English. In: **IEEE Access** 9 (2021), pp. 14369–14386.
13. G. Carneiro. "Artistic image analysis using graph-based learning approaches." English. In: **IEEE Transactions on Image Processing** 22.8 (2013), pp. 3168–3178.
14. S. Liu, J. Yang, S. Agaian, and C. Yuan. "Novel features for art movement classification of portrait paintings." In: **Image and Vision Computing** 108 (2021).
15. W. Zhao, D. Zhou, X. Qiu, and W. Jiang. "How to represent paintings: A painting classification using artistic comments." In: **Sensors** 21.6 (2021), pp. 1–15.
16. C. Jacobsen and M. Nielsen. "Stylometry of paintings using hidden Markov modelling of contourlet transforms." English. In: **Signal Processing** 93.3 (2013), pp. 579–591.
17. S. Eskimez, Y. Zhang, and Z. Duan. "Speech Driven Talking Face Generation from a Single Image and an Emotion Condition." English. In: **IEEE Transactions on Multimedia** (2021).
18. D. de Andrade, N. Fachada, C. Fernandes, and A. Rosa. "Generative art with swarm landscapes." English. In: **Entropy** 22.11 (2020), pp. 1–16.
19. K. Min, M. Dang, and H. Moon. "Deep Learning-Based Short Story Generation for an Image Using the Encoder-Decoder Structure." English. In: **IEEE Access** 9 (2021), pp. 113550–113557.
20. D. Zhou, K. Sun, M. Hu, and Y. He. "Image generation from text with entity information fusion." English. In: **Knowledge-Based Systems** 227 (2021).
21. M. Adamik, J. Goga, J. Pavlovicova, A. Babinec, and I. Sekaj. "Fast robotic pencil drawing based on image evolution by means of genetic algorithm." English. In: **Robotics and Autonomous Systems** 148 (2022).
22. X. Yang, Z. Ma, L. Yu, Y. Cao, B. Yin, X. Wei, Q. Zhang, and R. Lau. "Automatic Comic Generation with Stylistic Multi-page Layouts and Emotion-driven Text Balloon Generation." English. In: **ACM Transactions on Multimedia Computing, Communications and Applications** 17.2 (2021).

23. N. Matsumura, H. Tokura, Y. Kuroda, Y. Ito, and K. Nakano. "Tile art image generation using parallel greedy algorithm on the GPU and its approximation with machine learning." In: **Concurrency and Computation: Practice and Experience** 33.12 (2021).
24. W. Liu, X. Tong, Y. Xu, H. Shum, and H. Zhong. "Artistic image generation by deviation mapping." English. In: **International Journal of Image and Graphics** 1.4 (2001), pp. 565–574.
25. A. Kasao and K. Miyata. "Algorithmic Painter: A NPR method to generate various styles of painting." English. In: **Visual Computer** 22.1 (2006), pp. 14–27.
26. J. Li. "Simulation of oil painting art design based on 5 G mobile network and dynamic image sampling." English. In: **Microprocessors and Microsystems** 82 (2021).
27. N. Abe, M. Toyoura, and X. Mao. "Example-based painterly image generation using GIST." Japanese. In: **Journal of the Institute of Image Electronics Engineers of Japan** 41.4 (2012), pp. 340–351.
28. S. Seo, S. Ryoo, and K. Yoon. "Artistic image generation for emerging multimedia services by impressionist manner." English. In: **Transactions on Embedded Computing Systems** 12.2 (2013).
29. L. Gieseke, P. Asente, R. M  ch, B. Benes, and M. Fuchs. "A Survey of Control Mechanisms for Creative Pattern Generation." English. In: **Computer Graphics Forum** 40.2 (2021), pp. 585–609.
30. K. Babu and S. Dubey. "CSGAN: Cyclic-Synthesized Generative Adversarial Networks for image-to-image transformation." English. In: **Expert Systems with Applications** 169 (2021).
31. S. Naveen, M. Ram Kiran, M. Indupriya, T. Manikanta, and P. Sudeep. "Transformer models for enhancing AttnGAN based text to image generation." English. In: **Image and Vision Computing** 115 (2021).
32. R. Yi, M. Xia, Y.-J. Liu, Y.-K. Lai, and P. Rosin. "Line Drawings for Face Portraits from Photos Using Global and Local Structure Based GANs." English. In: **IEEE Transactions on Pattern Analysis and Machine Intelligence** 43.10 (2021), pp. 3462–3475.
33. A. Siarohin, S. Lathuili  re, E. Sangineto, and N. Sebe. "Appearance and Pose-Conditioned Human Image Generation Using Deformable GANs." English. In: **IEEE Transactions on Pattern Analysis and Machine Intelligence** 43.4 (2021), pp. 1156–1171.
34. S.-C. Chen, H. Cui, P. Tan, X. Sun, Y. Ji, H. Duh, and M. Pot  l. "Cantonese Porcelain Image Generation Using User-Guided Generative Adversarial Networks." English. In: **IEEE Computer Graphics and Applications** 40.5 (2020), pp. 100–107.